BLUEPRINT TEKNIS FINALISASI NOTEBOOK & UPGRADE METODOLOGI

Kompetisi GEMATIK VI 2026 – Cabang Data Science (Universitas Teknokrat Indonesia)

Tema Lomba: "Empowering Global Innovators for an Intelligent Future"
Basis Codebase: `029_082_100_159_Project_ML.ipynb`

---

1. OPSI USULAN JUDUL PROYEK

Tiga usulan judul berikut dirancang untuk menonjolkan integrasi sekuensial, *Graph Analytics*, *Cascade Clustering*, dan *Explainable Quantile Regression*:

- **Opsi 1 (Fokus Arsitektur End-to-End & Preskriptif - Paling Direkomendasikan):**
  "SkillGraph-AI: Arsitektur Multi-Task NLP Sekuensial Berbasis Self-Trained JobBERT NER, Two-Stage HDBSCAN-GMM Cascade Clustering, Analisis Topologi Graf Kompetensi, dan Explainable Quantile Stacking Ensemble untuk Intelijen Pasar Kerja Global"
- **Opsi 2 (Fokus Valuasi Ekonomi & Pemetaan Kompetensi):**
  "Sistem Intelijen Pasar Kerja Terintegrasi: Ekstraksi Entitas Semi-Supervised JobBERT, Pemetaan Taksonomi Okupasi HDBSCAN-GMM, dan Estimasi Rentang Kompensasi Berbasis SHAP-Quantile Ensemble"
- **Opsi 3 (Ringkas & Padat Gaya IEEE):**
  "Integrasi Sekuensial Multi-Model JobBERT NER, Klasterisasi Hibrida HDBSCAN-GMM, dan Quantile Stacking Regression dengan Analisis Jaringan Kompetensi pada Korpus Pasar Kerja"

---

2. PEMETAAN KESESUAIAN DENGAN KRITERIA PENILAIAN GEMATIK VI

Kriteria Penilaian	Bobot	Strategi Pemenuhan dari Eksekusi Notebook
1. Keaslian (Uji Plagiarisme)	20%	Kode dan visualisasi baru (Graph Network, Cascade Clustering, Ablation Study, SHAP, Quantile Interval) menghasilkan grafik dan tabel orisinal yang belum pernah dipublikasikan.
2. Kebaruan Dataset atau Metode	20%	**Kebaruan Dataset:** Penciptaan *Hybrid Annotated Corpus* (1.000 sampel anotasi manual `B-CERT`/`I-CERT` + *pseudo-labeling* threshold 0.85 menghasilkan 221.630 entitas terstruktur & matriks multimodal 612 dimensi).**Kebaruan Metode:** *Sequential Feature Fusion* (Output Task A & B menjadi input Task C), *Two-Stage HDBSCAN-GMM Cascade* untuk mengatasi 31,8% *noise*, dan *PMI Skill Network Topology*.
3. Manfaat	20%	Menghasilkan valuasi harga per keahlian (dalam USD), rentang negosiasi gaji ($P_{10}-P_{90}$), dan rekomendasi *Bridge Skills* yang relevan dengan SDG 4, SDG 8, SDG 9, SDG 17, serta kebijakan *Link and Match* (Perpres No. 68/2022) & Struktur Skala Upah (PP No. 36/2021).
4. Kejelasan Analisis & Visualisasi	20%	Mengganti visualisasi dasar dengan grafik berdensitas informasi tinggi: *PMI Skill Network Graph*, *Cascade Noise*

Kriteria Penilaian	Bobot	Strategi Pemenuhan dari Eksekusi Notebook
		Decomposition Plot, *Ablation Study Bar Chart*, dan *SHAP Beeswarm Plot*.
5. Kelengkapan Eksperimen	20%	Eksperimen mencakup *preprocessing* terukur (*Confirmatory EDA*), validasi *clustering* multi-metrik (Silhouette, DBI, CHI, DBCV, BIC/AIC), hingga *Ablation Study* pada regresi.

---

3. STRATEGI PENANGANAN DATASET DI NOTEBOOK

1. **Posisi Dataset secara Ilmiah:** Gunakan dataset dasar LinkedIn Job Postings (2023–2024, 123.849 baris $\rightarrow$ *stratified/filtered sample* 10.000 baris) secara jujur sebagai *raw baseline corpus* (merepresentasikan pasar kerja pasca-pandemi yang stabil, mengingat pembatasan API/anti-scraping ketat pada 2025–2026).
2. **Klaim Kontribusi Data di Notebook:** Tunjukkan lewat sel ringkasan data bahwa tim tidak memakai data mentah begitu saja, melainkan membangun **Dataset Multimodal Baru** yang terdiri dari:
    - **1.000 Kalimat Berlabel Manual (`CERT`)** + perluasan *Self-Training Pseudo-Labeling* (threshold 0.85).
    - **221.630 Span Entitas Terstruktur** (`SKILL`, `KNOWLEDGE`, `CERT`) yang dipetakan ke 10.000 lowongan.
    - **Matriks Fitur Terintegrasi (612 Dimensi)** yang menyatukan embedding semantik, leksikal, struktural, topologi klaster, dan kepadatan entitas NER.

---

4. AUDIT & DAFTAR MODIFIKASI PADA NOTEBOOK

Saat ini notebook terdiri dari 3 cabang yang berjalan paralel namun belum saling menyuplai fitur ke hilir (Task C belum memakai hasil Task A dan Task B). Berikut adalah bedah teknis bagian yang dipertahankan dan bagian yang harus ditambahkan/diubah:

A. Bagian Preparation & Preprocessing

- **Status:** Pertahankan 95% (Sudah sangat kuat).
- **Hal yang Dipertahankan:** Normalisasi gaji tahunan (`PERIOD_MULTIPLIER`), pembersihan teks (Unicode, HTML, URL, 13 pola *boilerplate* EEO), *regex parsing* untuk `years_exp_req` dan `education_level`, serta visualisasi *Confirmatory EDA* (Perbandingan panjang kata mentah vs bersih, penghapusan URL & *boilerplate*).
- **Penyesuaian Kecil:** Pastikan dataframe `df` hasil *preprocessing* (`jobs_clean.parquet`) menyimpan indeks `job_id` yang konsisten agar penggabungan fitur dari Task A dan Task B ke Task C tidak mengalami *misalignment*.

B. Task A: NER Skill, Knowledge, & Certification Extraction

- **Kondisi Saat Ini di Notebook:** Menggunakan `jjzha/jobbert_skill_extraction`, `jjzha/jobbert_knowledge_extraction`, dan model `CERT` hasil *fine-tuning* mandiri dengan aturan prioritas `CERT > SKILL > KNOWLEDGE > O`. Output visual saat ini baru berupa *WordCloud*, *Donut Chart* proporsi (61% Skill, 37,6% Knowledge, 1,4% Cert), *Bar Chart Top 20*, *Confusion Matrix CERT*, dan *Co-occurrence Heatmap 8×8*.
- **Penambahan/Perbaikan yang Harus Dilakukan (Upgrade 1 & 2):**
    a. **Tambahkan Tabel Metrik Evaluasi Lengkap (`seqeval` Classification Report):** Selain *Confusion Matrix* token `B-CERT` dan `I-CERT`, cetak tabel metrik **Precision, Recall, dan F1-Score** di level *entity span* pada *validation/test set* anotasi manual agar bukti kuantitatifnya lengkap.
    b. **Bangun "PMI Skill & Knowledge Co-occurrence Network Graph" (`NetworkX`):**
        - *Masalah Lama: Heatmap* 8×8 hanya menampilkan kata generik seperti *"communication skills"* dan *"bachelor's degree"* yang muncul di semua lowongan.
        - *Solusi Kode Baru:* Buat *filter* untuk memisahkan *Generic Soft Skills* dan bangun jaringan graf (`networkx.Graph`) khusus untuk **Top 40 Hard Skills, Tools (Knowledge), dan Certifications**. Gunakan bobot **Pointwise Mutual Information (PMI)** atau *Jaccard Similarity* pada *edge*-nya.
        - *Hitung Metrik Graf:* Hitung **PageRank Centrality** (kompetensi paling sentral di pasar kerja) dan **Betweenness Centrality** (*Bridge Skills* — kompetensi penghubung lintas domain industri).
        - *Visualisasi Baru:* Plot *Network Graph* berwarna berdasarkan komunitas (*Louvain/Greedy Modularity Communities*) dan cetak tabel **Top 10 High-Centrality & Bridge Skills**.
    c. **Ekspor Fitur Agregat NER untuk Task C:** Simpan kolom baru ke dataframe utama: `ner_skill_count`, `ner_knowledge_count`, `ner_cert_count`, `has_certification` (binary 0/1), dan `skill_diversity_ratio` (`unique_entities / desc_word_count`).

C. Task B: Semantic Job Clustering (SBERT + UMAP + HDBSCAN vs GMM)

- **Kondisi Saat Ini di Notebook:** Menggunakan *sliding-window chunking* (window 200 kata, stride 150, overlap 50) pada SBERT `all-MiniLM-L6-v2` $\rightarrow$ *mean pooling* $\rightarrow$ *L2 normalization* $\rightarrow$ UMAP (10D untuk klasterisasi, 2D untuk visualisasi) $\rightarrow$ Komparasi HDBSCAN (37 klaster, *coverage* 68,2%, *noise* 31,8%) vs GMM (8 komponen via BIC/AIC).
- **Kelemahan Kritis:** HDBSCAN membuang **3.180 lowongan (31,8% dari total data)** ke dalam *Noise Cluster (-1)*.
- **Penambahan/Perbaikan yang Harus Dilakukan (Upgrade 3):**
    a. **Implementasikan "Two-Stage HDBSCAN-GMM Cascade Clustering" pada Data Noise (-1):**
        - Ambil subset data dengan label `hdbscan_label == -1` ($n = 3.180$).
        - Ambil vektor UMAP 10D dan probabilitas keanggotaan GMM (`gmm_probs`) untuk 3.180 titik *noise* tersebut.
        - Hitung **Shannon Entropy** dari distribusi probabilitas GMM tiap titik *noise*:

```
entropy = -np.sum(probs * np.log(probs + 1e-12), axis=1)
```

        - **Klasifikasikan ulang 3.180 titik Noise menjadi 3 Sub-Kategori Bermakna:**
            - *Sub-Tipe 1: Hybrid / Cross-Functional Roles* (Titik *noise* yang memiliki probabilitas signifikan terbagi di 2 komponen GMM berbeda dan memiliki jumlah entitas `KNOWLEDGE` tinggi, misal: *Bioinformatics Data Scientist* atau *Legal Tech Compliance*).
            - *Sub-Tipe 2: Niche / Ultra-Specialized Roles* (Titik *noise* dengan *confidence* tinggi pada 1 komponen namun kepadatan lokalnya kurang dari `min_cluster_size=50`).
            - *Sub-Tipe 3: Generic Staffing / Boilerplate Postings* (Titik *noise* dengan *entropy* tinggi/ambigu dan didominasi oleh industri *Staffing and Recruiting* dengan sedikit entitas teknis).
    b. **Visualisasi Baru:** Buat grafik **Noise Cluster Decomposition Bar/Scatter Plot** dan tabel perbandingan gaji rata-rata antara *Core Clusters (37 klaster)*, *Hybrid Roles*, dan *Generic Staffing Postings*.
    c. **Ekspor Fitur Klaster untuk Task C:** Simpan kolom `hdbscan_cluster_id`, `gmm_cluster_id`, `gmm_max_confidence`, dan `cluster_entropy` ke dataframe utama.

D. Task C: Salary Regression & Explainable AI

- **Kondisi Saat Ini di Notebook:** Filter gaji $30.000–$250.000 ($n = 9.725$), target `log1p(salary_mid)`. Matriks fitur 604 dimensi (384 SBERT title+300 char + 150

TF-IDF SVD + 70 fitur terstruktur/keyword/interaksi). Model: Tuned XGBoost ($R^2 = 0.6502$), Tuned LightGBM ($R^2 = 0.6522$), dan Stacking Ensemble dengan RidgeCV ($R^2 = 0.6603$, MAE = $19.847).

- **Kelemahan Kritis:**
    a. Matriks 604 dimensi belum menggunakan fitur hasil Task A (NER) dan Task B (Clustering).
    b. Hanya menghasilkan prediksi titik tunggal (*point prediction*).
    c. *Feature Importance* belum menggunakan SHAP.
    d. Terjadi kendala ekspor pipeline model ke dashboard.
- **Penambahan/Perbaikan yang Harus Dilakukan (Upgrade 4, 5, & 6):**
    a. **True End-to-End Feature Fusion & Ablation Study (604 Dimensi $\rightarrow$ ~614 Dimensi):**
        - Tambahkan **10 fitur baru hasil Task A & Task B** ke dalam matriks fitur Task C:
            - Dari Task A (NER): `ner_skill_count`, `ner_knowledge_count`, `ner_cert_count`, `has_certification`, `hard_to_soft_skill_ratio`.
            - Dari Task B (Clustering): `hdbscan_cluster_te` (*out-of-fold target-encoded cluster salary*), `gmm_cluster_te`, `gmm_entropy`, `is_hybrid_role`, dan fitur interaksi `seniority_x_cluster_te`.
        - Latih ulang *Stacking Ensemble* pada matriks fitur baru (~614 dimensi) dan buat **Tabel & Grafik Ablation Study** yang membandingkan performa:
            - *Baseline 1:* Hanya Fitur Terstruktur & Keyword
            - *Baseline 2:* Terstruktur + Teks (SBERT + TF-IDF SVD) [604 fitur lama]
            - *Proposed Full Model:* Terstruktur + Teks + **NER Features (Task A) + Semantic Cluster Features (Task B)** [614 fitur baru].
    b. **Quantile Regression untuk Prediksi Rentang Gaji (P_{10}, P_{50}, P_{90}):**
        - Tambahkan model `LGBMRegressor(objective='quantile', alpha=0.10)` (batas bawah gaji konservatif) dan `alpha=0.90` (batas atas gaji optimis).
        - Evaluasi menggunakan metrik **Pinball Loss (Quantile Loss)** dan **Prediction Interval Coverage Probability (PICP)** (persentase gaji aktual pada data uji yang jatuh di dalam pita prediksi $P_{10}-P_{90}$).
        - Buat visualisasi **Salary Prediction Interval Plot** untuk 50 sampel uji yang diurutkan dari gaji terendah ke tertinggi.
    c. **SHAP Monetary Valuation Analysis (`shap.TreeExplainer`):**

        - Jalankan `shap` pada model terbaik untuk menghasilkan **SHAP Beeswarm Summary Plot** dan **SHAP Bar Plot of Top 15 Monetary Drivers**.
        - Konversi nilai SHAP dari skala logaritmik ke **Nilai Tambah Dolar (USD Marginal Impact)**.
    d. **Perbaikan Pipeline Penyimpanan Model untuk Dashboard (`joblib` Wrapper):**
        - Simpan objek `StackingRegressor` yang sudah terlatih beserta kamus *Target Encoding* (`location_te_map`, `industry_te_map`, `cluster_te_map`), objek `tfidf_vectorizer`, dan `svd_model` ke dalam satu *dictionary artifact* `production_bundle.joblib`.

---

5. RINGKASAN OUTPUT BARU YAN GDIHASILKAN DARI FINALISASI NOTEBOOK

Setelah menjalankan sel-sel tambahan pada `029_082_100_159_Project_ML.ipynb`, dihasilkan **6 Aset Visual & Tabel Baru**:

1. `fig_ner_network.png`: **Grafik Jaringan Topologi Kompetensi (PMI Skill & Knowledge Network)** + Tabel *Top 10 Bridge Skills* (Berdasarkan PageRank & Betweenness Centrality).
2. `fig_noise_cascade.png`: **Visualisasi Dekomposisi Noise HDBSCAN-GMM Cascade** (Membedah 3.180 data *noise* menjadi *Hybrid Cross-Domain Roles*, *Niche Roles*, dan *Agency Boilerplate*).
3. `table_ablation_study.csv` & `fig_ablation.png`: **Bukti Eksperimen Ablation Study** yang menunjukkan peningkatan R^2 dan penurunan MAE/RMSE ketika fitur NER (Task A) dan Klaster HDBSCAN (Task B) diintegrasikan ke dalam Regresi Gaji (Task C).
4. `fig_quantile_intervals.png`: **Grafik Pita Ketidakpastian Gaji (Quantile Prediction Intervals $P_{10} - P_{90}$)** beserta skor *Pinball Loss* dan *Coverage Probability*.
5. `fig_shap_beeswarm.png` & `fig_shap_monetary.png`: **Analisis Explainable AI (SHAP)** dan tabel **Valuasi Ekonomi Kompetensi (dalam USD/tahun)**.
6. `production_bundle.joblib`: Artefak model produksi terpadu yang siap diintegrasikan ke *Web Dashboard*.

---

6. ARAH INTERPRETASI INSIGHT, SDGs, DAN KONTEKSTUALISASI KEBIJAKAN

Interpretasi dari 6 output baru di atas diarahkan ke poin-poin strategis berikut:

1. **Rekomendasi Kurikulum Adaptif & "Bridge Skills" (Mendukung SDG 4 & Perpres No. 68 Tahun 2022):**
    - Hasil *NER* (61% *soft skills* vs 37,6% *hard knowledge*) dan *Network Centrality* membuktikan bahwa penguasaan *hard skill* teknis (seperti *Python, SQL, Cloud, Financial Auditing*) harus dipasangkan dengan *co-occurring soft skills* (*communication, cross-functional leadership*).
    - Identifikasi *Bridge Skills* memberikan panduan berbasis data bagi perguruan tinggi tentang mata kuliah/sertifikasi lintas disiplin yang paling efektif mendongkrak daya saing lulusan.
2. **Transparansi Kompensasi & Struktur Skala Upah (Mendukung SDG 8 & PP No. 36 Tahun 2021):**
    - Hasil **SHAP Monetary Valuation** dan **Quantile Regression ($P_{10}-P_{90}$)** memberikan rujukan objektif bagi pencari kerja dan praktisi HR dalam menyusun struktur dan skala upah berbasis bobot kompetensi, tingkat senioritas, dan lokasi geografis (`interact_sen_loc`, Spearman $r = 0.551$).
3. **Pembaruan Taksonomi Pekerjaan Modern (Mendukung SDG 9 & Klasifikasi Baku Jabatan Indonesia / KBJI):**
    - Keberhasilan **Two-Stage HDBSCAN-GMM Cascade** mengidentifikasi 37 klaster okupasi spesifik ditambah sub-klaster *Hybrid/Cross-Functional Roles* (dari kelompok *noise*) menunjukkan bahwa taksonomi pekerjaan statis pemerintah sering tertinggal oleh kemunculan profesi hibrida baru di era AI. Sistem ini menawarkan pemetaan taksonomi okupasi otomatis secara *real-time*.
4. **Sinergi Ekosistem Ketenagakerjaan (Mendukung SDG 17):**
    - Integrasi ke dalam prototipe *Web Dashboard* menjembatani asimetri informasi antara talenta pencari kerja, institusi pendidikan, dan industri global.